

FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA – FIAP

GUSTAVO LIMA MARTINS

**OTIMIZAÇÃO DE FLUXOS LOGÍSTICOS HOSPITALARES VIA
ALGORITMOS GENÉTICOS: UM ESTUDO DE CASO NO HOSPITAL
ISRAELITA ALBERT EINSTEIN**

SÃO PAULO, 2026

SUMÁRIO

1. INTRODUÇÃO	1
2. FUNDAMENTAÇÃO TEÓRICA	2
2.1. SELEÇÃO	2
2.2. CRUZAMENTO	2
2.3. MUTAÇÃO	2
3. METODOLOGIA	3
3.1. REPRESENTAÇÃO DO INDIVÍDUO (CROMOSSOMO)	3
3.2. FUNÇÃO DE APTIDÃO (FITNESS)	5
3.2.1. Custo de viagem	5
3.2.2. Penalidade de capacidade	5
3.2.3. Penalidade de autonomia	5
3.2.4. Penalidade de custo	5
3.2.5. Penalidades de criticidade (alta e crítica)	6
3.3. LARGE LANGUAGE MODEL E FINE-TUNNING VIA RAG	6
3.4. CICLO DE EXECUÇÃO DO ALGORITMO GENÉTICO	7
4. RESULTADOS E DISCUSSÃO	8
4.1. ALGORITMO GENÉTICO	8
4.2. LLM INTERFACE	10
4.2.1. Interação 1: Pergunta sobre estratégias técnicas	10
4.2.2. Interação 2: Pergunta sobre sugestão de melhorias	11
4.2.3. Interação 3: Pergunta sobre padrões presentes	12
5. CONCLUSÃO	13
6. REFERÊNCIAS BIBLIOGRÁFICAS	16

LISTA DE FIGURAS

Figura 1 - Diagrama da geração do cromossomo para cada indivíduo da população	4
Figura 2 - Diagrama da arquitetura de integração da LLM no algoritmo genético	6
Figura 3 - Diagrama do fluxo de execução do algoritmo genético com <i>setup</i> do estudo	7
Figura 4 - Bloco de código <i>python</i> com <i>setup</i> da estratégia de validação cruzada utilizada	8
Figura 5 - Interação 1 com LLM: pergunta sobre as estratégias técnicas	10
Figura 6 - Interação 2: Pergunta sobre sugestões de melhoria na roteirização	11
Figura 7 - Interação 3: Pergunta sobre reconhecimento de padrões na roteirização.....	12
Figura 8 - Progressão do valor de <i>fitness</i> em função das novas gerações	13
Figura 9 - Trajetos reais para cada rota via <i>Google Maps</i>	14

LISTA DE TABELAS

Tabela 1 - Roteirização geográfica mais eficiente da melhor solução gerada.....	9
Tabela 2 - Alocação de entregas mais eficiente por rota e veículo da melhor solução gerada	9

1. INTRODUÇÃO

A logística hospitalar está situada no setor terciário da economia, todavia, possui interface com o secundário, devido à industrialização e manufatura, portanto, tal aspecto multilateral tacitamente expressa o alto grau de complexidade operacional e elevada criticidade de eficiência envolvidos.

Consoante a isso, há inúmeros casos de imperícia na logística hospitalar que culminam em prejuízos sociais e financeiros, um exemplo disso ocorreu durante a pandemia de COVID-19, quando o secretário de saúde do Distrito Federal reconheceu a falta de EPIs em hospitais públicos, atribuída a falhas logísticas durante a pandemia (G1, 2020). Além disso, a falta de inteligência na cadeia de suprimentos gerou desperdício em larga escala, uma vez que o almoxarifado central do Ministério da Saúde perdeu cerca de R\$ 2,2 bilhões em medicamentos e insumos médicos desde 2019, cuja causa foi atribuída às falhas de logística e gestão de estoques (AGÊNCIA BRASIL, 2023).

No entanto, novas tecnologias orientadas por algoritmos e inteligência artificial tem surgido para auxiliar na resolução do problema (TERRA, 2025), sobretudo os algoritmos genéticos têm desempenhado relevante papel nos sistemas de roteirização modernos. Por isso, visando promover uma solução para logística hospitalar, foi desenvolvido um estudo de caso aplicado à instituição Albert Einstein, para tanto, foram consideradas 15 unidades espalhadas pela cidade de São Paulo, assim como 5 veículos com características diferentes na frota e 25 entregas distintas a serem realizadas, com diversidades de configurações entre si (volume, prioridade e destino).

Portanto, o objetivo do algoritmo genético consistiu em elaborar a melhor roteirização possível, por meio da heurística, ao considerar restrições relevantes ao contexto hospitalar, com uma interface conversacional capaz de responder em linguagem natural sobre o funcionamento, a estrutura e fundamentação matemática do algoritmo, além de explicar os parâmetros da melhor roteirização encontrada, outrossim sugerir eventuais sugestões de melhoria e identificar padrões consistentes que forneçam *insights*.

Logo, o projeto desenvolvido em linguagem *python* está disponível em repositório *online*, contendo a arquitetura completa, além dos eventuais arquivos resultantes do fluxo de execução do algoritmo (MARTINS, 2026).

2. FUNDAMENTAÇÃO TEÓRICA

Os operadores genéticos utilizam-se de múltiplas estratégias intrínsecas às soluções bio-inspiradas, através das quais operam: cruzamento, mutação e seleção. Logo, estabeleceu-se quais técnicas seriam empregadas em cada eixo.

2.1. SELEÇÃO

Conforme aborda a pesquisa de otimização logística para redes de energia renovável dos pesquisadores Sadeghi e Haapala (2017), o emprego do torneio entre os indivíduos da população é indicado, outrossim, houve a incorporação da estratégia de elitismo defendida por Kang e Chang (2021) para assegurar a preservação das melhores rotas logísticas.

2.2. CRUZAMENTO

RBX [4], *route based crossover*, foi escolhido por ser um *benchmark* longo aplicado especificamente aos problemas de otimização da roteirização, além de lidar com cromossomo no nível de rota, conforme a estrutura requer.

Outrossim, BCRC [5], *best cost route crossover*, introduziu um método orientado pelo custo da rota, tal fator demonstrou alta aderência ao presente contexto.

2.3. MUTAÇÃO

WANG et al. (2022) apresentou a adequação da técnica de *swap mutation* no cenário da otimização logística entre a distância de múltiplos centros de distribuição, da mesma forma, GULIĆ et al. (2022) aplicou a *relocate mutation* com o intuito de buscar uma solução que minimizasse a quantidade necessária de movimentações entre itens para preencher um contêiner, desse modo, utilizou-se dessas estratégias para redução do deslocamento e quantidade mínima de rotas necessárias concomitantemente, a cada nova geração de soluções.

3. METODOLOGIA

Para fins de detalhamento da solução foi elaborada uma metodologia contendo: representação do indivíduo (cromossomo), função de aptidão (fitness) e os operadores genéticos (seleção, cruzamento e mutação).

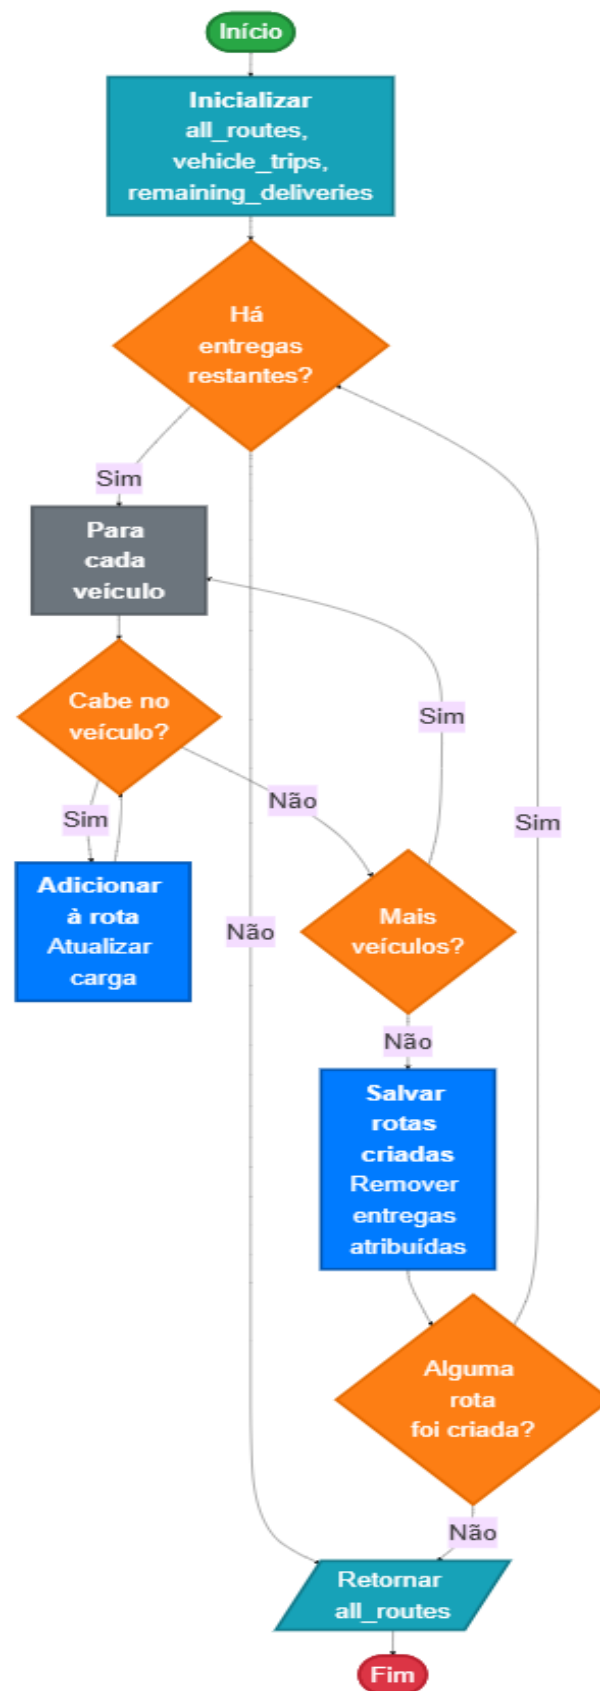
3.1. REPRESENTAÇÃO DO INDIVÍDUO (CROMOSSOMO)

Inicialmente os indivíduos são representados por meio de uma associação entre veículos e entregas, desta forma, há um codificador responsável por gerar o cromossomo composto exclusivamente pelas entregas.

A partir disso, o cromossomo é decodificado, considerando a restrição de capacidade máxima de cada veículo para alocação plausível das entregas, com o intuito de fornecer a roteirização sequencial das entregas por veículo, no formato adequado para função de leitura manipular os metadados de cada veículo e entrega. Ademais disso, a figura 1 ilustra o processo enumerado na seguinte ordem:

- Carregar primeira amostra de todas as rotas, viagens por veículo e entregas não incluídas
- Avaliar se é necessário nova rodada de geração de rota
- Considerar a restrição de capacidade máxima por veículo
- Verificar disponibilidade de outro veículo quando a carga não couber
- Quando todas as entregas possuírem roteirização então terminar

Figura 1 - Diagrama da geração do cromossomo para cada indivíduo da população



Fonte: Autoria própria, 2026

3.2. FUNÇÃO DE APTIDÃO (FITNESS)

A equação geral da função de aptidão pode ser descrita na seguinte notação matemática:

$$F = \sum_{i=1}^n [C_i + P_i^{capacidade} + P_i^{autonomia} + P_i^{custo} + (P_i^{criticidade_3} + P_i^{criticidade_2})]$$

Onde n = número total de rotas. Para cada rota i , temos:

3.2.1. CUSTO DE VIAGEM

$$C_i = d_i \times c_i$$

Onde d_i = distância Manhattan da rota i e c_i = custo por metro do veículo i

3.2.2. PENALIDADE DE CAPACIDADE

$$P_i^{capacidade} = \begin{cases} 100 \times (L_i - K_i), & \text{se } L_i > K_i \\ 0, & \text{caso contrário} \end{cases}$$

Onde L_i = carga atual da rota i e K_i = capacidade máxima do veículo i

3.2.3. PENALIDADE DE AUTONOMIA

$$P_i^{autonomia} = \begin{cases} 200 \times (d_i - A_i), & \text{se } d_i > A_i \\ 0, & \text{caso contrário} \end{cases}$$

Onde A_i = autonomia máxima do veículo i

3.2.4. PENALIDADE DE CUSTO

$$P_i^{custo} = \begin{cases} 5 \times \left(\frac{c_i}{|R_i|} - 5 \right), & \text{se } \frac{c_i}{|R_i|} > 5 \\ 0, & \text{caso contrário} \end{cases}$$

Onde R_i = número de entregas na rota i

3.2.5. PENALIDADES DE CRITICIDADE (ALTA E CRÍTICA)

$$p_i^{criticidade_3} = \sum_{j \in R_i P_j=3} (i \times 12 + pos_j \times 1.5 + i^2 \times 2.0)$$


$$p_i^{criticidade_2} = \sum_{j \in R_i P_j=3} (i \times + pos_j \times 0.6)$$

Onde P_j = prioridade de entrega (2, 3) e pos_j = posição da entrega j na rota

3.3. LARGE LANGUAGE MODEL E FINE-TUNNING VIA RAG

A integração da LLM foi adotada usando o serviço de API da OpenAI, com o modelo *gpt-4.1-mini*, com *fine-tuning* realizado via *RAG*, a estratégia de *datawarehouse* utilizou um *vector database chroma*, conforme ilustra a figura 2, a partir disso, foi definido um agente especializado em logística hospitalar, cujo é capaz de interpretar os metadados da melhor solução via *fitness* e *metrics*, ambos armazenados em um único arquivo no formato *json*.

Figura 2 - Diagrama da arquitetura de integração da LLM no algoritmo genético

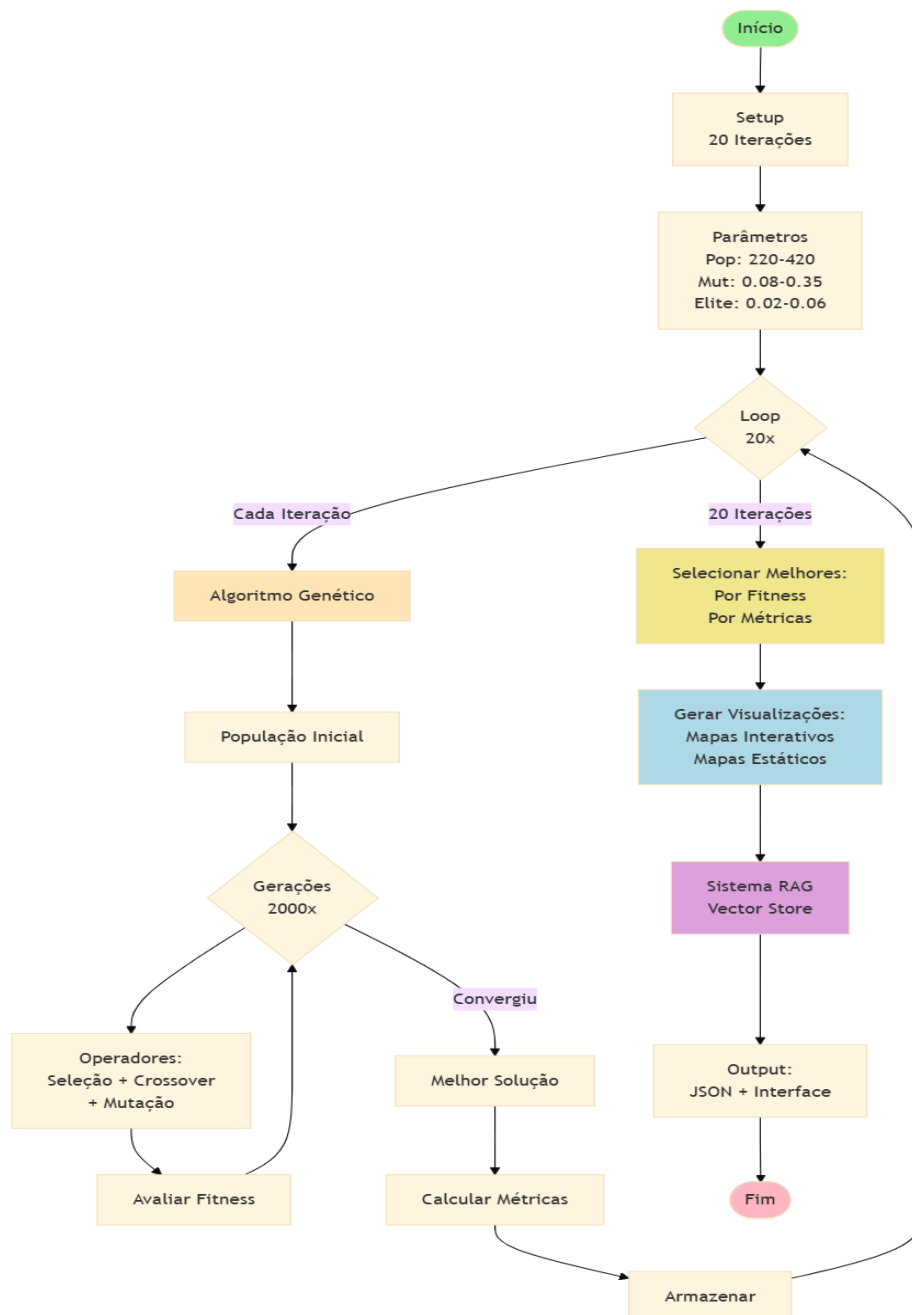


Fonte: Autoria própria, 2026

3.4. CICLO DE EXECUÇÃO DO ALGORITMO GENÉTICO

O processo de execução do algoritmo genético é apresentado pela figura 3, na qual observa-se que a arquitetura inclui validação cruzada, através da inclusão de n iterações com configurações variáveis entre: p de população inicial, g do máximo de gerações, k competidores do torneio, taxa e de elitismo e m de mutação; para fomentar a diversidade do espaço de procura, em cada iteração.

Figura 3 - Diagrama do fluxo de execução do algoritmo genético com *setup* do estudo



4. RESULTADOS E DISCUSSÃO

4.1. ALGORITMO GENÉTICO

Objetivando realizar a validação cruzada, a execução do algoritmo genético foi configurada para lidar com 20 cenários mutuamente distintos entre si, com abordagens que incluem, progressivamente, valores mais altos inicialmente e mais baixos posteriormente, considerando a população inicial, máximo de gerações, taxa de elitismo, mutação e número de participantes do torneio, conforme demonstra minunciosamente a figura 4.

Figura 4 - Bloco de código *python* com *setup* da estratégia de validação cruzada utilizada

```
if __name__ == "__main__":
    solutions = Solution(total_iterations=20)
    city_code = "SP"

    solutions.heuristic_loop(
        city_code=city_code,
        population_length=(
            350, 380, 420, 320, 400, 360, 300, # Regime A (7)
            300, 320, 340, 360, 280, 330, 350, # Regime B (7)
            260, 240, 280, 220, 250, 270      # Regime C (6)
        ),
        max_generations=(2000,) * 20,
        ratio_elitism=(
            0.02, 0.02, 0.03, 0.02, 0.03, 0.03, 0.02,
            0.03, 0.03, 0.04, 0.04, 0.03, 0.04, 0.03,
            0.05, 0.05, 0.04, 0.06, 0.05, 0.04
        ),
        ratio_mutation=(
            0.30, 0.28, 0.35, 0.32, 0.25, 0.27, 0.33,
            0.18, 0.20, 0.15, 0.17, 0.22, 0.16, 0.19,
            0.10, 0.12, 0.09, 0.08, 0.11, 0.10
        ),
        tournament_k=(
            2, 2, 3, 2, 3, 3, 2,
            3, 3, 4, 4, 3, 4, 3,
            4, 4, 4, 4, 4, 4
        )
    )
```

Sendo assim, após a execução completo do ciclo evolutivo em cada um dos cenários preparados, foi encontrada a melhor solução na iteração 10, geração 1079, com valor de fitness igual a 865.44, neste caso, a roteirização geográfica mais performática, através do método heurístico, é apresentada na tabela 1.

Tabela 1 - Roteirização geográfica mais eficiente da melhor solução gerada

Rota	Veículo	Sequência de Atendimento
R1	V1	CD → Einstein Jardins → Einstein Parque Ibirapuera → Einstein Ibirapuera → Einstein Morumbi → CD
R2	V2	CD → Einstein Alphaville → CD
R3	V3	CD → Einstein Anália Franco → Espaço Einstein Bem-Estar e Saúde Mental → CD
R4	V4	CD → Espaço Einstein Bem-Estar e Saúde Mental → CD
R5	V5	CD → Espaço Einstein Esporte e Reabilitação → CD
R6	V1	CD → Einstein Perdizes → Einstein Alto de Pinheiros → CD
R7	V2	CD → Einstein Vila Mariana → Einstein Chácara Klabin → CD
R8	V3	CD → Einstein Parque da Cidade → CD
R9	V4	CD → Centro de Terapias Avançadas → Einstein Morumbi → CD
R10	V1	CD → Einstein Jardins → Einstein Ibirapuera → CD

Fonte: Autoria própria, 2026

Além disso, a alocação de entregas por veículo mais performática paralelamente à roteirização geográfica, é descrita na tabela 2.

Tabela 2 - Alocação de entregas mais eficiente por rota e veículo da melhor solução gerada

Rota	Veículo	Entregas
R1	V1	18, 9, 6, 20, 1
R2	V2	23, 15, 2
R3	V3	4, 13
R4	V4	21
R5	V5	14
R6	V1	10, 16, 19, 25, 3
R7	V2	11, 5, 17
R8	V3	8
R9	V4	12, 24
R10	V1	7, 22

Fonte: Autoria própria, 2026

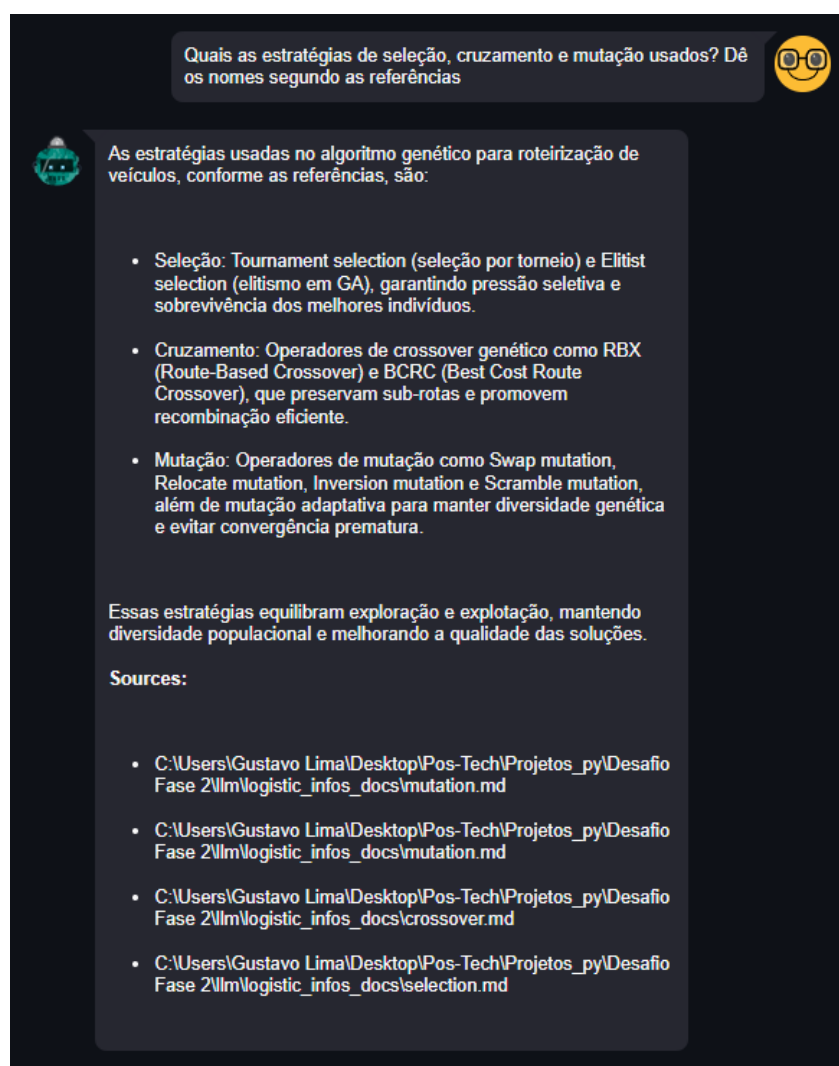
4.2. LLM INTERFACE

A interface integrada consistiu em LLM com *fine-tuning* RAG, que foi capaz de responder com coerência mediante diversas perguntas em linguagem natural, incluindo explicação específica acerca das estratégias do algoritmo, fornecer sugestões de melhoria e até reconhecer padrões relevantes entre os metadados da solução.

4.2.1. INTERAÇÃO 1: PERGUNTA SOBRE ESTRATÉGIAS TÉCNICAS

A figura 5 apresenta a primeira resposta da LLM diante de uma pergunta relativa ao uso de estratégias para seleção, cruzamento e mutação.

Figura 5 - Interação 1 com LLM: pergunta sobre as estratégias técnicas

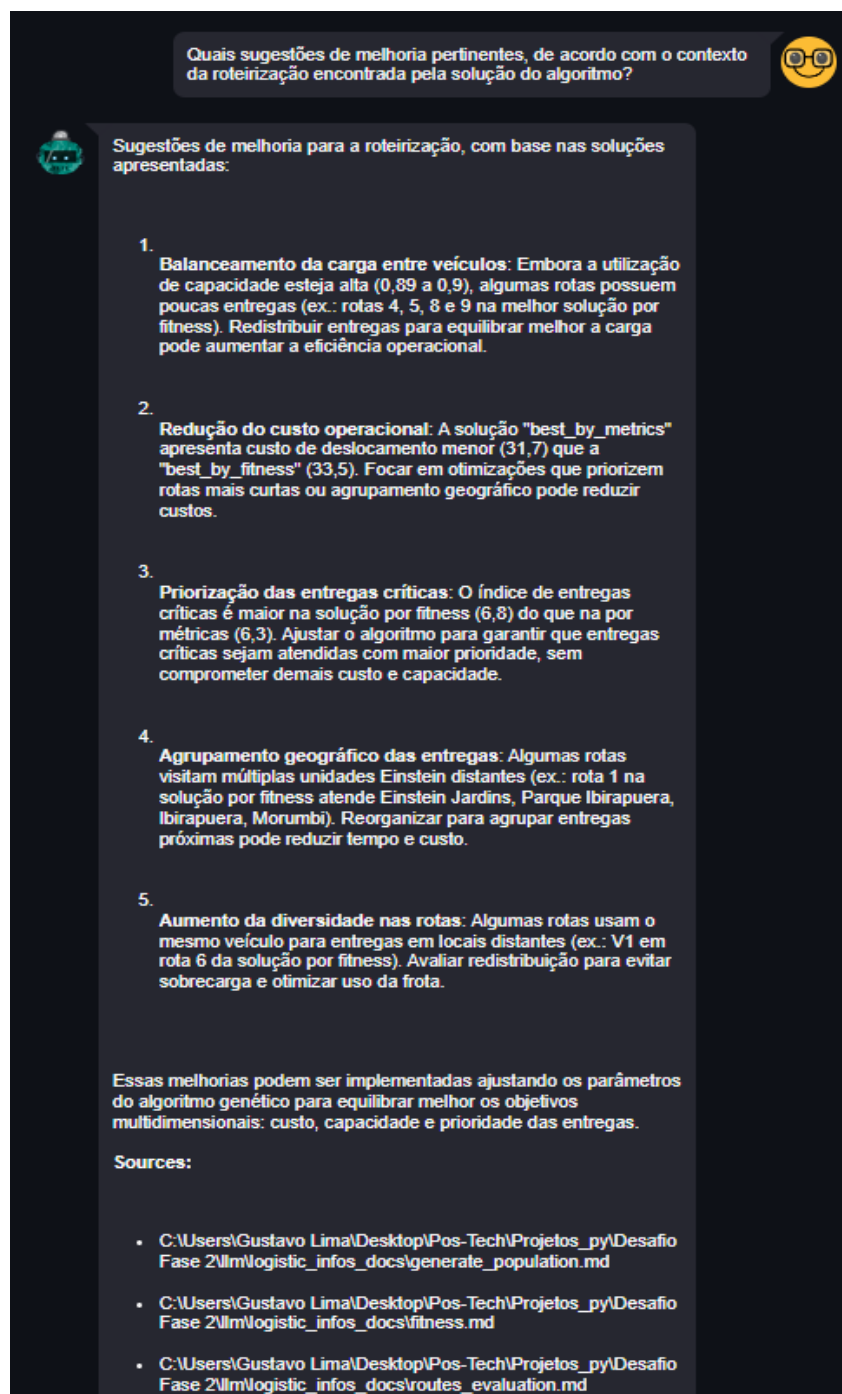


Fonte: Autoria própria, 2026

4.2.2. INTERAÇÃO 2: PERGUNTA SOBRE SUGESTÃO DE MELHORIAS

Outra notável capacidade da LLM contextualizada foi observada, com base no conhecimento robusto do algoritmo, assim como da solução encontrada, a figura 6 demonstra uma resposta contendo sugestões de melhoria plausíveis à roteirização.

Figura 6 - Interação 2: Pergunta sobre sugestões de melhoria na roteirização

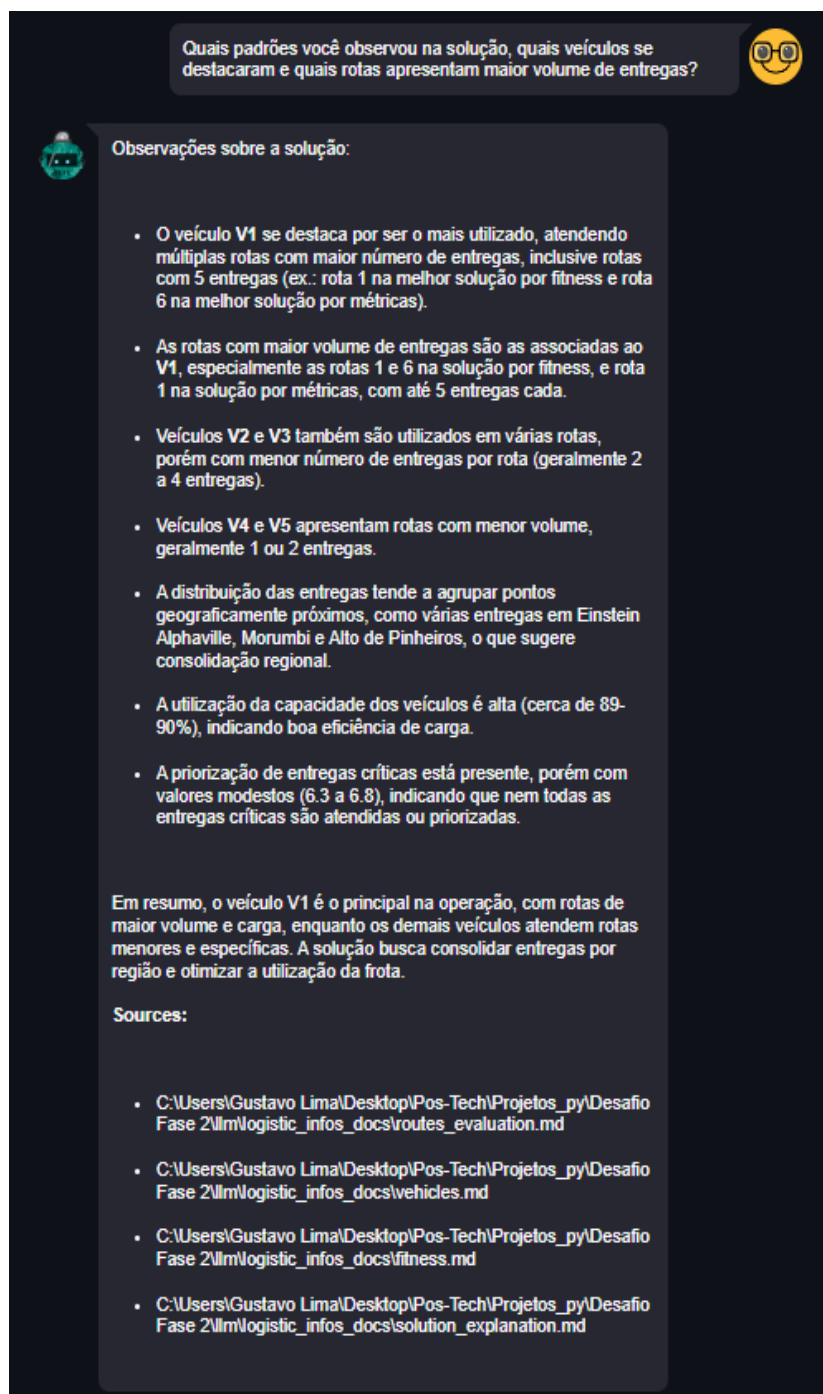


Fonte: Autoria própria, 2026

4.2.3. INTERAÇÃO 3: PERGUNTA SOBRE PADRÕES PRESENTES

Por fim, houve ainda uma última interação de exemplo, que consistiu em medir a capacidade de reconhecimento de padrões na roteirização, a qual demonstrou-se pertinente para obtenção de insights, conforme apresenta a figura 7.

Figura 7 - Interação 3: Pergunta sobre reconhecimento de padrões na roteirização




5. CONCLUSÃO

O presente estudo de caso aplicado à instituição Albert Einstein logrou êxito em corroborar a aplicabilidade dos algoritmos genéticos, no contexto da logística hospitalar, tendo em vista a escolha de técnicas de *benchmark* para seleção, cruzamento e mutação, assim como, a abordagem heurística orientada por restrições realistas, incluídas na função de fitness, com o emprego da validação cruzada em 20 cenários mutuamente exclusivos, tais aspectos foram capazes de incutir robustez ao processo evolutivo.

Outrossim, observa-se a incidência da curva de Pareto na progressão do valor de fitness em função do número de gerações, conforme indica a figura 8, algo que indica a manutenção de genes qualitativos, isto é, a preservação de combinações eficientes entre veículos, rotas e entregas, todavia, com a capacidade de explorar novos arranjos ao longo da evolução do algoritmo, uma vez que a melhor solução encontrada se situou na geração 1079.

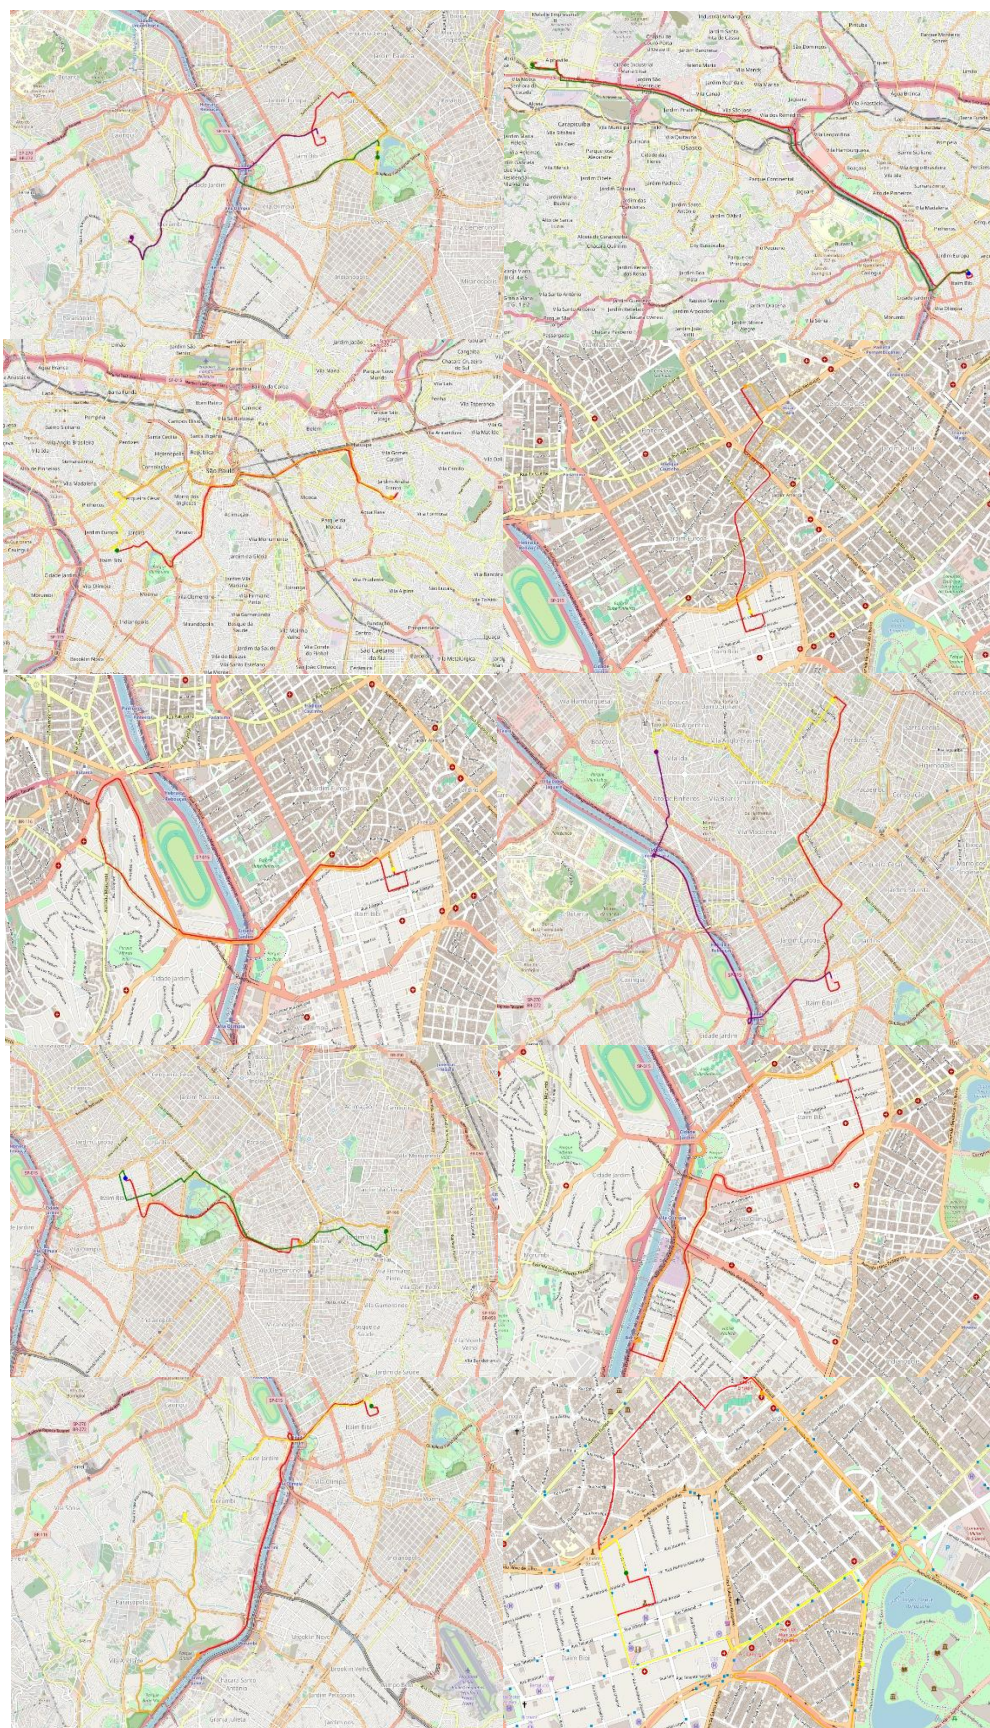
Figura 8 - Progressão do valor de *fitness* em função das novas gerações



Fonte: Autoria própria, 2026

Ademais disso, com a integração do Google Maps, foi possível desenhar todas as 10 rotas de entrega com deslocamento no tráfego real, considerando a saída do centro de distribuição (CD), as paradas entre hospitais e o retorno ao CD. Consoante a isso, a figura 10 apresenta todos os trajetos reais a serem percorridos pela frota.

Figura 9 - Trajetos reais para cada rota via *Google Maps*



Fonte: Autoria própria, 2026

Todavia, a complexidade dos problemas baseados em *TSP*, no âmbito hospitalar, é demasiadamente multifatorial, ou seja, outras restrições relevantes podem ser inseridas no dimensionamento da função de *fitness*, tais como o tempo de deslocamento e o uso da quilometragem percorrida ao invés de unidades cartesianas Manhattan. Além disso, uma abordagem de mutação progressiva na iteração pode ser adotada, para fomentar a diversidade no espaço de procura por novas soluções subótimas. Outro fato reside em aumentar a quantidade de cenários mutuamente exclusivos, com novas combinações pertinentes, para expor o algoritmo evolutivo em contextos mais amplos e consequentemente buscar novas soluções mais performáticas.

Portanto, vale ressaltar que a fase atual de desenvolvimento é embrionária, logo, suscetível a melhorias significativas, porém, ainda sim demonstrou-se promissora e com alto potencial de agregar valor à logística hospitalar, com a otimização heurística desempenhando papel fundamental para conciliar eficiência e agilidade na confecção da roteirização.

6. REFERÊNCIAS BIBLIOGRÁFICAS

1. G1. *Secretário de Saúde reconhece falta de EPIs em hospitais do DF e atribui problema a falha de logística durante a pandemia*. G1 – Distrito Federal, 09 nov. 2020. Disponível em: <https://g1.globo.com/df/distrito-federal/noticia/2020/11/09/secretario-de-saude-reconhece-falta-de-epis-em-hospitais-do-df-e-atribui-problema-a-falha-de-logistica-durante-pandemia.ghtml>. Acesso em: 08 jan. 2025.
2. AGÊNCIA BRASIL. *Perda de insumos do Ministério da Saúde soma R\$ 2 bilhões desde 2019*. Agência Brasil, 27 abr. 2023. Disponível em: <https://agenciabrasil.ebc.com.br/saude/noticia/2023-04/perda-de-insumos-do-ministerio-da-saude-soma-r-2-bilhoes-desde-2019>. Acesso em: 08 jan. 2025.
3. TERRA. *Tecnologia otimiza logística hospitalar e laboratorial*. Disponível em: <https://www.terra.com.br/noticias/tecnologia-otimiza-logistica-hospitalar-e-laboratorial,430c1e90112febbfe1b3f3ee9f94d520ezuhca9z.html>. Acesso em: 08 jan. 2025.
4. MARTINS, G. L. *GeneticAlgorithmForHospital-sLogistic (Version 2.0)* [Python software for genetic algorithm]. GitHub. <https://github.com/GustavoLimaMartins/GeneticAlgorithmForHospital-sLogistic> Acesso em: 13 jan. 2026.
5. J.-Y. POTVIN, S. BENGIO. *The vehicle routing problem with time windows part ii: genetic search*, INFORMS Journal on Computing 8 (1996) 165–172.

6. B. OMBUKI, B. J. ROSS and F. HANSHAR, — *Multi-Objective Genetic Algorithms for Vehicle Routing Problem with Time Windows*, II Springer Science + Business Media, Inc. Manufactured in The Netherlands, 2006.

7. WANG, Yong *et al.* *Collaborative multi-depot logistics network design with time window assignment*. Expert Systems with Applications, [S. l.], v. 188, p. 116035, fev. 2022.

8. GULIĆ, Marko *et al.* *Solving the Container Relocation Problem by Using a Metaheuristic Genetic Algorithm*. Journal of Marine Science and Engineering, [S. l.], v. 10, n. 4, p. 494, abr. 2022.

9. SADEGHI, Javad; HAAPALA, Karl R. *Renewable Energy Network Using a Genetic Algorithm*. *Procedia Manufacturing*, [S. l.], v. 10, p. 730-739, 2017.

10. KANG, Jiarong; CHANG, Menghuai. *The Application of Elite Genetic Algorithm in Sustainable Agricultural Transportation*. ACM International Conference Proceeding Series, New York, p. 1–5, 2024. DOI: <https://doi.org/10.1145/3658549.3658551>.